Étiquetage géométrique de la cible par barycentres de Wasserstein et transport optimal hiérarchique pour l'adaptation de domaine multi-sources et multimodale

Kevin Djoumessi
Faculté des Sciences, Université de Yaoundé I, Yaoundé, Cameroun
kevin.djoumessi@facsciences-uy1.cm

Compléter la liste des auteurs et des affiliations.

30 octobre 2026

Résumé

Contexte. L'adaptation de domaine multi-sources et multimodale (MSMMDA) vise à étiqueter un domaine cible sans étiquette à partir de plusieurs domaines sources étiquetés, chaque exemple étant décrit par plusieurs modalités. **Limite de l'état de l'art.** La méthode de référence, M2CAN, aligne les représentations par des pertes contrastives puis entraîne un classifieur sur l'espace fusionné ; les méthodes de transport optimal hiérarchique, HOT-DA et WBHR, étiquettent la cible par la géométrie mais opèrent après coup, sur des caractéristiques fixes, et sans fusion multimodale. **Solution proposée.** Nous supprimons le classifieur sur l'espace fusionné et plaçons l'étiquetage géométrique à l'intérieur de l'entraînement : chaque classe source est agrégée, à travers les sources, par un barycentre de Wasserstein ; la cible est partitionnée par un algorithme spectral ; un transport optimal à deux niveaux, entre structures puis entre points, suivi d'un appariement hongrois, affecte une classe à chaque groupe. Cet étiquetage est exécuté périodiquement et fournit des pseudo-étiquettes, filtrées par l'accord des têtes unimodales, à une perte contrastive supervisée sur l'espace fusionné. **Résultats.** Sur des caractéristiques gelées (CLIP, AST), dans un protocole apparié par cible et par graine avec des protocoles écrits avant les mesures, la méthode atteint le niveau de M2CAN réglé sur deux familles sur trois (actions HAC : 88,64 contre 88,36 ; esthétique : 65,07 contre 63,99 ; écarts non significatifs) et lui est inférieure sur l'analyse de sentiment ($-8{,}45$). Les pseudo-étiquettes apportent $+7{,}19$ points sur HAC (IC95 $[+2{,}22; +12{,}17]$). L'étude d'ablation montre que l'appariement des groupes aux classes est optimal dans la quasi-totalité des runs, que le barycentre et la taille de son support n'affectent pas les étiquettes, que le transport hiérarchique devance le transport plat ($+2{,}31$, tendance non significative), et que le facteur limitant est l'existence d'une structure en groupes dans l'espace fusionné, absente pour des classes ordinales comme la polarité d'un sentiment.

1 Introduction

Contexte et motivation. Les systèmes d'apprentissage sont entraînés sur des données qui ne sont pas celles de leur usage : les domaines diffèrent par la source des exemples, leur style ou leur capteur. L'adaptation de domaine non supervisée cherche à prédire les étiquettes d'un domaine cible, pour lequel seules des entrées sont disponibles, à partir de domaines sources étiquetés [1]. Deux extensions se sont imposées. L'adaptation multi-sources (MDA) exploite plusieurs sources qui ne se recouvrent pas ; l'adaptation multimodale (MMDA) traite des exemples décrits par plusieurs modalités, par exemple un texte et une image, ou une piste audio et une vidéo. Leur conjonction, l'adaptation multi-sources et multimodale (MSMMDA), a été définie récemment par Zhao et al. [20] et répond à des applications concrètes : analyse de sentiment

sur des réseaux sociaux de styles différents, évaluation esthétique de photographies issues de plateformes distinctes, reconnaissance d'actions dans des vidéos humaines, animales ou de dessins animés.

Problème. Étant donné N domaines sources étiquetés et un domaine cible sans étiquette, chaque exemple ayant M modalités, prédire les étiquettes de la cible. La difficulté est triple : le décalage entre chaque source et la cible, le désaccord entre les sources elles-mêmes, et le désaccord possible entre les modalités d'un même exemple.

Limites de l'état de l'art. La méthode de référence pour la MSMMDA, M2CAN [20], aligne les représentations par des pertes contrastives entre modalités et entre domaines, les fusionne par un produit bilinéaire de rang faible, puis entraîne un classifieur sur l'espace fusionné. Ce classifieur n'est entraîné que sur les sources ; il transfère à la cible par la seule vertu de l'alignement, et rien ne garantit que la frontière apprise sur les sources respecte la structure de la cible. Du côté du transport optimal, HOT-DA [6] étiquette la cible par un transport entre structures (classes sources, groupes cibles) qui exploite explicitement la structure collective de la cible, et WBHR [8] l'étend au cas multi-sources par des barycentres de Wasserstein. Mais ces méthodes opèrent après coup, sur des caractéristiques fixes, sans apprentissage de représentation, et ne traitent pas la multimodalité.

Contributions.

1. Une méthode de MSMMDA qui remplace le classifieur sur l'espace fusionné par un étiquetage géométrique de la cible, dérivé de WBHR et de HOT-DA, et l'exécute pendant l'entraînement d'une fusion multimodale : les étiquettes géométriques, filtrées par l'accord des modalités, servent de pseudo-étiquettes à une perte contrastive supervisée sur l'espace fusionné (Section 3). La méthode accepte un nombre quelconque de sources et de modalités.
2. Une comparaison appariée à M2CAN sur trois familles de jeux, à caractéristiques gelées identiques, mêmes graines et mêmes découpes, avec des protocoles écrits avant les mesures (Section 4). La méthode atteint le niveau de M2CAN sur deux familles et lui est inférieure sur la troisième.
3. Une étude d'ablation et une analyse du mécanisme : apport des pseudo-étiquettes, rôle du barycentre, du transport hiérarchique et du classifieur final de WBHR, et diagnostics qui localisent le facteur limitant dans la partition de la cible plutôt que dans l'appariement.

Organisation. La Section 2 situe la méthode. La Section 3 la décrit : architecture, formalisation, agrégation par barycentre, transport hiérarchique, perte et entraînement. La Section 4 présente l'environnement expérimental, les résultats, l'étude d'ablation, l'analyse et la discussion. La Section 5 conclut. Le code, les configurations, les protocoles et les résultats sont publics. [1]

2 Travaux connexes

2.1 Adaptation de domaine multi-sources

L'adaptation multi-sources traite plusieurs domaines étiquetés dont aucun ne coïncide avec la cible. Les approches par transport optimal représentent chaque domaine par une mesure empirique et déplacent les sources vers la cible [1]. Montesuma and Mboula [15] agrègent les sources en un barycentre de Wasserstein avant de transporter ce barycentre vers la cible ; WBHR [8] agrège plutôt chaque classe à travers les sources par un barycentre à support libre [3], puis applique un transport hiérarchique. Nous reprenons cette agrégation par classe.

1. https://github.com/Kevindjoum/MM-WBHR

2.2 Adaptation de domaine multimodale

L'adaptation multimodale exploite plusieurs modalités par exemple. Les revues de Dong et al. [5] et Li and Tang [13] en donnent le panorama ; SimMMDG [4] introduit le jeu HAC pour la généralisation multimodale, que nous utilisons en adaptation. M2CAN [20] définit le cadre MSMMDA, publie six jeux textes et images, et propose une fonction de coût à quatre termes : entropie croisée sur des têtes unimodales, alignement contrastif entre modalités pondéré par la cohérence des têtes (CMCFA), alignement contrastif supervisé entre domaines (CDCFA), et classifieur sur une fusion bilinéaire de rang faible [11]. Nous reprenons les trois premiers termes et remplaçons le quatrième par un étiquetage géométrique.

2.3 Transport optimal hiérarchique

Le transport optimal régularisé par l'entropie [2, 16] permet de calculer des plans de transport et des barycentres [3] à grande échelle. HOT-DA [6] organise le transport sur deux niveaux : au niveau haut, chaque domaine est une mesure sur des *structures*, les classes pour la source et des groupes obtenus par partition pour la cible, et le coût entre deux structures est leur distance de Wasserstein ; au niveau bas, chaque structure source est transportée vers la structure cible qui lui est appariée. El Hamri et al. [7] en donnent des garanties. SHOT [14] combine, dans un autre cadre, une maximisation de l'information sur la cible et des pseudo-étiquettes par centres de classes ; nous évaluons la première comme option. Notre apport par rapport à HOT-DA et WBHR est de placer le transport hiérarchique dans la boucle d'entraînement d'une fusion multimodale, comme source de pseudo-étiquettes, et de supprimer le classifieur final.

3 Méthode proposée

3.1 Architecture

La Figure 1 montre l'architecture. Chaque modalité est encodée séparément par une dorsale gelée et un extracteur entraîné, et possède une tête de classification unimodale. Les représentations des modalités sont fusionnées dans un espace z par un produit bilinéaire de rang faible (fusion intermédiaire). Aucun classifieur n'est entraîné sur z : les classes de la cible y sont lues par la géométrie, en trois étapes exécutées périodiquement pendant l'entraînement. D'abord, chaque classe source est agrégée, à travers les N sources, par un barycentre de Wasserstein. Ensuite, la cible est partitionnée en K groupes et un transport optimal de niveau haut, entre barycentres et groupes, apparie chaque groupe à une classe ; le niveau bas est le transport entre points qui fournit les coûts du niveau haut. Enfin, les étiquettes obtenues, filtrées par l'accord des têtes unimodales (fusion tardive des décisions), entrent dans une perte contrastive supervisée sur z et façonnent l'espace que la géométrie lit au tour suivant.

3.2 Formalisation du problème

On dispose de N domaines sources étiquetés $\mathcal{S}_i = \{(x_j^i, y_j^i)\}_{j=1}^{n_i}$, $i = 1, \dots, N$, et d'un domaine cible $\mathcal{T} = \{x_j\}_{j=1}^{n}$ sans étiquette. Chaque exemple possède M modalités ordonnées $x = (x_0, \dots, x_{M-1})$ et appartient à l'une de K classes communes à tous les domaines. Le train cible sert à l'entraînement sans ses étiquettes ; le test cible sert à l'évaluation, ses étiquettes ne servant qu'à mesurer l'exactitude. L'inférence est transductive : la méthode partitionne un ensemble de points cibles et ne prédit pas un point isolé.

Encodeurs et têtes. Pour la modalité m, une dorsale gelée b_m fournit un vecteur de dimension d_m ; un extracteur linéaire $W_m \in \mathbb{R}^{256 \times d_m}$ suivi d'une normalisation donne

$$e_m = \frac{\mathrm{ReLU}(W_m\, b_m(x_m))}{\|\mathrm{ReLU}(W_m\, b_m(x_m))\|} \in \mathbb{R}^{256}. \tag{1}$$

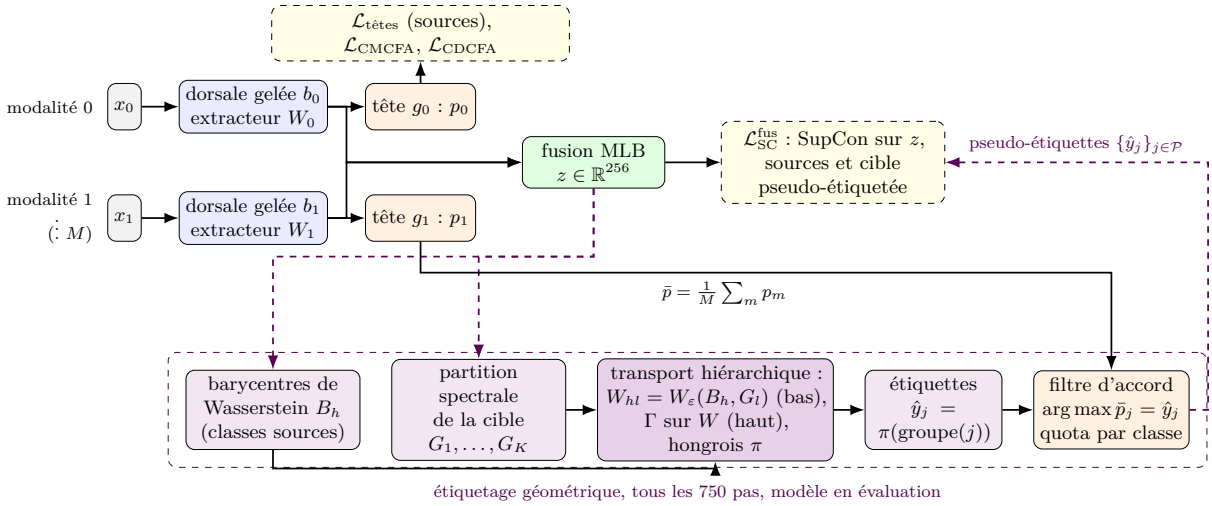


FIGURE 1 – Architecture de la méthode. Rangée du haut : passe avant à chaque pas (encodeurs, têtes, fusion, pertes). Rangée du bas : étiquetage géométrique périodique sur z, dont les étiquettes, filtrées par l'accord des têtes, reviennent dans la perte contrastive sur l'espace fusionné.

Une tête unimodale g_m, perceptron $256 \to 128 \to 64 \to K$, produit $p_m = \text{softmax}(g_m(e_m))$.

Fusion. Les représentations sont fusionnées par un produit bilinéaire de rang faible [11], le même que M2CAN :

$$z = P\Big(\sigma\big(\bigodot_m U_m e_m\big)\Big) + \sum_m h_m(e_m) \in \mathbb{R}^{256}, \tag{2}$$

avec $U_m : \mathbb{R}^{256} \to \mathbb{R}^{128}$, $P : \mathbb{R}^{128} \to \mathbb{R}^{256}$, $h_m : \mathbb{R}^{256} \to \mathbb{R}^{256}$ linéaires, σ la sigmoïde et $\odot$ le produit terme à terme. Aucun classifieur n'est entraîné sur z.

Mesures et transport. Dans z, le coût entre deux points est le coût cosinus $c(u,v) = \|u/\|u\| - v/\|v\|\|^2 = 2 - 2\cos(u,v) \in [0,4]$. Pour une matrice de coût C et deux mesures discrètes a et b, le plan de transport régularisé par l'entropie

$$\Gamma^\star(a,b,C) = \underset{\Gamma\mathbf{1}=a,\ \Gamma^\top\mathbf{1}=b}{\arg\min} \ \langle \Gamma, C\rangle - \varepsilon H(\Gamma) \tag{3}$$

est calculé par l'algorithme de Sinkhorn en domaine logarithmique [2]. Le coût de transport entre deux nuages X et Y de poids uniformes est $W_\varepsilon(X,Y) = \langle \Gamma^\star, C\rangle$ avec $C_{ij} = c(x_i, y_j)$. Comme dans HOT-DA, la classe h de la source i est la mesure empirique uniforme ρ_h^i sur ses points C_h^i, et le groupe l de la cible est la mesure uniforme ϱ_l sur ses points ; chaque domaine est une mesure uniforme sur ses structures, $\varphi_{\mathcal{S}_i} = \frac{1}{K}\sum_h \delta_{\rho_h^i}$ et $\varphi_{\mathcal{T}} = \frac{1}{K}\sum_l \delta_{\varrho_l}$.

3.3 Agrégation des structures sources par barycentre

Les N sources ne partagent pas la même distribution de la classe h. Plutôt que de choisir une source ou de concaténer les nuages, nous résumons la classe par le barycentre de Wasserstein de ses N nuages [3, 8],

$$\rho_h^{\text{aux}} = \arg\min_{\kappa} \frac{1}{N}\sum_{i=1}^{N} W_\varepsilon(\kappa, \rho_h^i), \tag{4}$$

cherché à support libre : un nuage $B_h = (b_1, \ldots, b_S)$ de S points de poids $1/S$. Il est calculé par point fixe (Algorithme 1) : B_h est initialisé par S points tirés dans l'union des nuages ; à chaque itération, le plan Γ_i entre B_h et C_h^i est calculé pour chaque source, puis chaque point est remplacé par la moyenne de ses projections barycentriques. Le barycentre représente la classe

telle que les sources la partagent, au sens du transport optimal. Nous utilisons $S = 16$, $\varepsilon = 0{,}02$, 60 itérations de Sinkhorn et 8 itérations de point fixe ; au plus 400 points par classe et par source sont tirés. La taille théorique du support dans WBHR, $\frac{1}{N}\sum_i |C_h^i|$, est évaluée en ablation.

Algorithme 1 : Barycentre de Wasserstein à support libre de la classe h

Input : nuages $C_h^1, \dots, C_h^N$; support S ; ε ; itérations I_{sink}, I_{iter}
Output : $B_h \in \mathbb{R}^{S\times 256}$

$B_h \leftarrow S$ points tirés dans $\bigcup_i C_h^i$; $a \leftarrow \frac{1}{S}\mathbf{1}_S$;
for $t = 1$ **to** I_{iter} **do**
  for $i = 1$ **to** N **do**
    $\Gamma_i \leftarrow \Gamma^\star(a,\ \frac{1}{|C_h^i|}\mathbf{1},\ c(B_h, C_h^i))$ par Sinkhorn, I_{sink} itérations;
  $b_s \leftarrow \dfrac{S}{N}\displaystyle\sum_{i=1}^{N}\sum_j \Gamma_i[s,j]\, x_j^i$ pour tout s ; `// projection barycentrique moyenne`
return B_h

3.4 Transport optimal hiérarchique vers la cible

La procédure ÉTIQUETER (Algorithme 2) reçoit les représentations z et les étiquettes des sources, et les z de n points cibles, et renvoie une classe pour chaque point cible.

Algorithme 2 : ÉTIQUETER : transport hiérarchique et appariement

Input : représentations et étiquettes des sources ; représentations cibles $Z_{\mathcal{T}} \in \mathbb{R}^{n\times 256}$; K
Output : étiquettes $\hat{y} \in \{1, \dots, K\}^n$, groupes, marges

foreach *classe* h **do**
  $B_h \leftarrow$ Algorithme 1 sur les nuages de classe h des N sources;
$C_{ij} \leftarrow c(z_i, z_j)$ pour $z_i, z_j \in Z_{\mathcal{T}}$; $\sigma \leftarrow$ médiane des $C_{ij} > 0$;
$A \leftarrow \exp(-C/\sigma)$, $A_{ii} \leftarrow 1$; $G_1, \dots, G_K \leftarrow$ partition spectrale de A [18];
foreach *classe* h, *groupe* l **do**
  $W_{hl} \leftarrow W_\varepsilon(B_h, G_l)$; `// niveau bas : transport entre points`
$\Gamma \leftarrow \Gamma^\star(\frac{1}{K}\mathbf{1}, \frac{1}{K}\mathbf{1}, W)$, 300 itérations ; `// niveau haut : transport entre structures`
$\pi \leftarrow$ appariement hongrois [12] maximisant $\sum_l \Gamma_{\pi(l),l}$;
$\hat{y}_j \leftarrow \pi(\text{groupe}(j))$ pour tout j;
$\text{marge}_j \leftarrow \min_{l\neq \text{groupe}(j)} c(z_j, \bar{c}_l) \,/\, c(z_j, \bar{c}_{\text{groupe}(j)})$, avec $\bar{c}_l$ le centre du groupe l;
return $\hat{y}$, *groupes, marges*

Niveau bas. Le coût entre la classe h et le groupe l est le coût de transport $W_\varepsilon(B_h, G_l)$ entre les points du barycentre et les points du groupe, avec le même $\varepsilon = 0{,}02$.

Niveau haut. Le transport entre $\varphi_{\mathcal{S}}^{\text{aux}} = \frac{1}{K}\sum_h \delta_{\rho_h^{\text{aux}}}$ et $\varphi_{\mathcal{T}}$ se résout par Sinkhorn sur la matrice $W \in \mathbb{R}^{K\times K}$ avec marges uniformes. Le plan Γ exprime quelle part de chaque classe va dans chaque groupe.

Appariement. L'algorithme hongrois appliqué à $-\Gamma$ apparie chaque groupe à une classe distincte. Il garantit la bijection, là où l'arg max par classe de WBHR peut envoyer deux classes sur le même groupe. Chaque point du groupe l reçoit la classe $\pi(l)$. WBHR, lui, transporte

ensuite les représentants vers leur groupe et entraîne un classifieur sur les points transportés ; nous évaluons cette fin en ablation et conservons l'étiquetage par groupe.

3.5 Fonction de perte et entraînement

À chaque pas, quatre exemples sont tirés dans chaque domaine, sources puis cible, avec une vue faible x et une vue augmentée $\tilde{x}$. La perte est

$$\mathcal{L} = \mathcal{L}_{\text{têtes}} + \mathcal{L}_{\text{CMCFA}} + \mathcal{L}_{\text{CDCFA}} + \mathcal{L}_{\text{SC}}^{\text{fus}}, \tag{5}$$

avec des poids égaux à 1. Les trois premiers termes sont ceux de M2CAN [20].

Têtes unimodales. Entropie croisée sur les sources, $\mathcal{L}_{\text{têtes}} = \frac{1}{MN} \sum_{i \le N} \sum_m \text{CE}(g_m(e_m^{(i)}), y^{(i)})$.

CMCFA. Alignement contrastif entre modalités, sur tous les domaines, cible comprise, sans étiquette. Pour un exemple x d'un lot, avec $a = e_0$ et $b = e_1$, l'InfoNCE sur les quatre combinaisons de vues vaut

$$\ell(x) = -\log \frac{\sum_{(u,v)} \exp \langle u_x,\, v_x \rangle}{\sum_{(u,v)} \sum_{x'} \exp \langle u_x,\, v_{x'} \rangle}, \qquad (u, v) \in \{a, \tilde{a}\} \times \{b, \tilde{b}\}. \tag{6}$$

La cohérence entre les têtes est $V(x) = \text{KL}(p_1 \,\|\, p_0)$ pour $M = 2$, la divergence de Jensen-Shannon des M têtes au-delà. Les exemples où les modalités se contredisent pèsent moins : $\mathcal{L}_{\text{CMCFA}} = \sum_d [\frac{1}{4} \sum_x \ell(x) e^{-V(x)} + \frac{1}{4} \sum_x V(x)]$. Avec $M \ge 3$, l'InfoNCE est moyenné sur les paires de modalités.

CDCFA. Perte contrastive supervisée [10] par modalité, sur les sources réunies, $\mathcal{L}_{\text{CDCFA}} = \sum_m \text{SupCon}(\{e_m^{(i)}\}, \{y^{(i)}\}, \tau)$ avec $\tau = 0{,}07$ et

$$\text{SupCon}(Z, Y, \tau) = -\frac{1}{|A|} \sum_{a \in A} \frac{1}{|P(a)|} \sum_{p \in P(a)} \log \frac{\exp(z_a \cdot z_p / \tau)}{\sum_{b \ne a} \exp(z_a \cdot z_b / \tau)}, \tag{7}$$

où $P(a)$ réunit les exemples de même étiquette que a et A ceux qui en ont au moins un.

SupCon sur l'espace fusionné. C'est le terme propre à la méthode, sur les sources et sur les exemples cibles du lot qui possèdent une pseudo-étiquette :

$$\mathcal{L}_{\text{SC}}^{\text{fus}} = \text{SupCon}\Big(\{z^{(i)}\}_{i \le N} \cup \{z_j^{\mathcal{T}}\}_{j \in \mathcal{P}},\ \{y^{(i)}\}_{i \le N} \cup \{\hat{y}_j\}_{j \in \mathcal{P}},\ \tau\Big). \tag{8}$$

Un point cible étiqueté h est attiré vers les exemples sources de la classe h dans z.

Pseudo-étiquettes. Tous les 750 pas, soit 15 tours $r = 0, \ldots, 14$ sur 3 époques, le modèle passe en évaluation ; ÉTIQUETER est appliquée aux z d'au plus 3000 exemples du train cible, et la prédiction moyenne des têtes $\bar{p}_j = \frac{1}{M} \sum_m p_{m,j}$ est calculée. Deux filtres s'appliquent. *Accord* : un point n'est retenu que si $\arg\max_h \bar{p}_{j,h} = \hat{y}_j$; les têtes, fusion tardive des décisions unimodales, ne décident pas, elles filtrent la décision géométrique. *Quota croissant* : avec $\rho_r = (0{,}3; 0{,}6; 0{,}9; 1{,}0)[\min(r, 3)]$ et n points étiquetés, on garde dans chaque classe au plus $\lfloor \rho_r n / K \rfloor$ points, ceux de plus grande marge. La table des points retenus remplace celle du tour précédent. Les vraies étiquettes du train cible ne servent qu'à journaliser la justesse des pseudo-étiquettes.

Optimisation et évaluation. Adam, $\beta = (0{,}9; 0{,}999)$, taux 5×10^{-5} pour les extracteurs, la fusion et les têtes, décroissance polynomiale $(1 - t/T)^{0{,}9}$ sur $T = 3 \times 3750$ pas. Après chaque tour, ÉTIQUETER est appliquée au test cible. Le résultat rapporté est celui du *dernier* point ; le meilleur point, choisi avec les étiquettes du test, serait optimiste et n'est jamais rapporté. Deux diagnostics sont journalisés : l'*oracle*, exactitude avec le meilleur appariement possible des groupes aux classes, qui mesure la seule partition ; et le *plancher logistique*, exactitude d'une régression logistique entraînée sur les z des sources et appliquée au test cible, qui mesure ce que vaut z sans étiquetage géométrique.

4 Expérimentation

4.1 Environnement expérimental

Jeux de données. Trois familles de trois domaines, chaque domaine servant de cible à tour de rôle, les deux autres étant les sources (Tableau 1). HAC [4] comprend des vidéos d'actions humaines, animales et de dessins animés, avec audio et vidéo, sept classes d'actions. Les familles sentiment (trois classes de polarité) et esthétique (deux classes) sont celles de M2CAN [20], avec texte et image. Les découpes sont celles des auteurs.

TABLE 1 – Jeux de données. Le test cible est l'ensemble sur lequel l'exactitude est mesurée.

famille	domaines	modalités (dimension)	K	test cible
HAC	human, animal, cartoon	audio AST (768), vidéo CLIP (512)	7	276 / 176 / 218
esthétique	AVA, PCCD, RPCD	texte CLIP (512), image CLIP (512)	2	847
sentiment	TumEmo, Twitter, Yelp	texte CLIP (512), image CLIP (512)	3	1500

Caractéristiques gelées. Toutes les méthodes reçoivent les mêmes vecteurs, extraits une fois par des encodeurs gelés : CLIP ViT-B/32 [17] pour le texte, l'image et la vidéo (moyenne de huit images par segment temporel [19]), AST [9] pour l'audio. Chaque exemple a une vue faible et quatre vues fortes, avec les augmentations de M2CAN. Pour M2CAN, les vecteurs sont complétés par des zéros jusqu'aux dimensions attendues par son code.

Références (baselines). *M2CAN publié* : code des auteurs adapté aux caractéristiques gelées, configuration publiée de chaque cible, 10 époques. Ses taux d'apprentissage sont prévus pour des encodeurs ajustés de bout en bout ; sur caractéristiques gelées, ils figent presque ses couches entraînables. *M2CAN réglé* : le taux d'extracteur est porté à 5×10^{-5}, le même que celui de notre méthode ; c'est la référence retenue pour toutes les comparaisons. *Sources seules* : régression logistique sur les deux modalités concaténées, entraînée sur les sources, sans adaptation. *Auto-apprentissage* : le même modèle avec cinq tours de pseudo-étiquetage par confiance. La méthode est entraînée 3 époques.

Métriques et statistiques. Exactitude sur le test cible au dernier point d'évaluation. Trois graines (123456, 234567, 345678) par cible, soit 9 runs par configuration et par famille. Les écarts entre deux configurations sont appariés par (cible, graine), 9 paires, avec un intervalle de confiance à 95 % de Student à 8 degrés de liberté. Un écart est déclaré en faveur d'une configuration si l'intervalle exclut zéro et si au moins 7 paires sur 9 sont de son côté ; il est *non significatif* sinon. Les protocoles (configurations, comparaisons, critère) ont été écrits avant chaque série de mesures. Les runs sont déterministes.

TABLE 2 – Exactitude au dernier point (%), moyenne sur trois graines, caractéristiques gelées. En gras, la meilleure valeur de chaque colonne parmi les méthodes d'adaptation. Les planchers ne sont pas appariés aux autres lignes.

	human	animal	cartoon	moyenne
HAC				
méthode	**93,36**	**96,40**	76,15	**88,64**
M2CAN réglé	87,68	95,45	**81,96**	88,36
M2CAN publié	86,23	86,17	77,06	83,16
sources seules / auto-apprentissage	73,79 / 88,04	86,55 / 92,80	71,10 / 81,35	77,15 / 87,40
	AVA	PCCD	RPCD	moyenne
esthétique				
méthode	**72,06**	62,06	**61,08**	**65,07**
M2CAN réglé	69,62	**62,42**	59,94	63,99
M2CAN publié	62,38	61,59	58,24	60,74
sources seules / auto-apprentissage	65,80 / 66,98	59,74 / 59,35	54,55 / 59,46	60,03 / 61,93
	TumEmo	Twitter	Yelp	moyenne
sentiment				
méthode	46,02	56,36	39,67	47,35
M2CAN réglé	**58,02**	**59,07**	**50,31**	**55,80**
M2CAN publié	52,18	47,89	37,73	45,93
sources seules / auto-apprentissage	51,64 / 55,13	52,07 / 55,49	50,44 / 51,31	51,38 / 53,98

TABLE 3 – Écarts appariés par (cible, graine), en points d'exactitude : moyenne, IC95, paires en faveur de la première configuration, verdict du protocole.

famille	comparaison	écart	IC95	paires / verdict
HAC	méthode − M2CAN réglé	+0,27	[−3,68; +4,22]	5/9, non significatif
esthétique	méthode − M2CAN réglé	+1,08	[−0,13; +2,28]	7/9, non significatif
sentiment	méthode − M2CAN réglé	−8,45	[−12,32; −4,58]	0/9, **moins bien**
HAC	M2CAN réglé − M2CAN publié	+5,21	[+2,41; +8,01]	8/9, mieux
esthétique	M2CAN réglé − M2CAN publié	+3,25	[+0,86; +5,64]	9/9, mieux
sentiment	M2CAN réglé − M2CAN publié	+9,87	[+6,40; +13,33]	9/9, mieux

4.2 Résultats

Les Tableaux 2 et 3 donnent le résultat principal. Sur HAC et sur l'esthétique, la méthode atteint le niveau de M2CAN réglé : +0,27 et +1,08 point, écarts non significatifs. Un étiquetage purement géométrique de l'espace fusionné y fait aussi bien qu'un classifieur entraîné sur cet espace, et dépasse les deux planchers. Sur HAC, la méthode devance M2CAN sur human (+5,7) et animal (+1,0) et reste derrière sur cartoon (−5,8), la cible la plus éloignée. Sur le sentiment, la méthode est inférieure à M2CAN réglé de 8,45 points sur les neuf paires, et passe sous le plancher sources seules (47,35 contre 51,38) : l'étiquetage géométrique y perd de l'information que les caractéristiques contiennent.

Le réglage du taux d'extracteur de M2CAN est déterminant : il apporte +5 à +10 points selon la famille. Les comparaisons à M2CAN publié, favorables à la méthode, tiennent à cette asymétrie de réglage et ne sont pas retenues.

4.3 Étude d'ablation

Chaque ablation retire ou remplace un seul élément de la méthode ; les protocoles ont été écrits avant les mesures. La Tableau 4 résume les résultats, détaillés ensuite.

TABLE 4 – Étude d'ablation, exactitude au dernier point (%), moyenne de neuf runs, et écart apparié à la méthode complète. n.s. : non significatif.

configuration	HAC	esthétique	sentiment
méthode complète	88,64	65,07	47,35
sans pseudo-étiquettes	81,44 (−7,19, 8/9)	66,16 (+1,09, 9/9)	48,68 (n.s.)
sans barycentre (concaténation des nuages)	88,64 (0,00)	non mesuré	
barycentre à support $\frac{1}{N}\sum_i \lvert C_h^i \rvert$	88,64 (0,00)	65,07 (0,00)	47,35 (0,00)
sans hiérarchie (transport plat vers les représentants)	86,33 (−2,31 n.s.)	non mesuré	
sans barycentre ni hiérarchie	86,57	non mesuré	
fin de WBHR (argmax, classifieur sur les représentants transportés)	88,10 (n.s.)	65,18 (n.s.)	50,88 (+3,53, 7/9)
fin de WBHR et support théorique	89,34 (n.s.)	65,16 (n.s.)	50,80 (+3,45, 9/9)
sans fusion multimodale	non mesuré : à compléter ou à retirer		

Sans pseudo-étiquettes. Sur HAC, les pseudo-étiquettes apportent +7,19 points (IC95 [+2,22; +12,17], 8/9) ; sur cartoon, elles font passer l'exactitude de 61,93 à 76,15. Les pseudo-étiquettes retenues sont justes à 94 à 97 % en fin d'entraînement sur human et animal, à 79 à 85 % sur cartoon. Sur une graine, la divergence MMD^2 entre la cible et les sources dans z est divisée par trois à six (cartoon : 0,120 → 0,020) et l'information mutuelle normalisée de la partition augmente (0,51 → 0,65). Sur l'esthétique et le sentiment, elles n'apportent rien et coûtent 1,09 point sur l'esthétique : la MMD^2 n'y bouge pas. Leur bénéfice dépend de la justesse de l'étiquetage géométrique qui les produit.

Sans barycentre.
Hypothèse H1. Le barycentre de Wasserstein des nuages d'une classe représente mieux cette classe que leur concaténation.

Sur HAC, avec un support de la taille moyenne de la classe afin que barycentre et concaténation aient des cardinalités comparables, le barycentre est plus proche, au sens du coût de transport, de la classe cible correspondante, dans 9 cas sur 9 (+0,022 en moyenne). Mais il produit exactement les mêmes étiquettes. Hypothèse H1 est partiellement vérifiée : le représentant est meilleur, mais il n'agit que sur l'appariement, qui est déjà optimal. Pour la même raison, la taille du support (16 points ou taille théorique de WBHR) ne change aucune étiquette sur les trois familles.

Sans hiérarchie.
Hypothèse H2. Le transport hiérarchique (partition, transport entre structures, appariement) étiquette mieux la cible qu'un transport direct des points cibles vers les points des représentants de classe.

Sur HAC, le transport hiérarchique devance le transport plat de +2,31 point (IC95 [−0,04; +4,65], 7/9), surtout sur animal (+5,9). L'intervalle touche zéro : Hypothèse H2 est une tendance favorable, non significative au sens du protocole.

Fin de WBHR. WBHR ne s'arrête pas à l'appariement : les points de chaque représentant B_h sont transportés vers leur groupe apparié par projection barycentrique, $\tilde{B}_h = |B_h|\,\Gamma^{\star}_{h,\hat{l}(h)}\,Z_{\hat{l}(h)}$,

un classifieur est entraîné sur $\bigcup_h \tilde{B}_h$ étiqueté h et appliqué à tous les points cibles. Cette fin n'aide que sur le sentiment (+3,45, 9/9), où elle dépasse l'oracle de la partition de 2,3 points : le classifieur n'est plus limité par les groupes. Elle ne change rien là où la partition est bonne et ne suffit pas à rattraper M2CAN réglé (−5,00, IC95 [−7,56; −2,44]) ni le plancher sources seules. La méthode conserve l'étiquetage par groupe.

4.4 Analyse

L'appariement n'est pas le facteur limitant. Dans 184 runs sur 198, l'exactitude au dernier point égale l'oracle de la partition ; les exceptions sont concentrées sur le sentiment (écart moyen 0,21 point, maximum 10,5). Tout ce qui sépare la méthode d'une exactitude parfaite tient donc à la partition de la cible, c'est-à-dire à l'existence, dans z, de K groupes qui coïncident avec les classes. C'est pourquoi le représentant, la taille de son support et l'appariement n'ont pas d'effet.

Leviers sur l'espace fusionné. Six configurations modifiant un seul élément de la méthode ont été mesurées (Tableau 5) : maximisation de l'information de SHOT [14] sur les têtes du lot cible (poids 0,3 et 1), perte SupCon de la fusion sur z normalisé, partition spectrale sur le graphe des 15 plus proches voisins, et combinaison de la fin de WBHR et de z normalisé. Aucune ne change HAC ni l'esthétique au-delà du bruit. Sur le sentiment, seule la maximisation de l'information aide (+3,07 avec le poids 1, borne basse de l'IC à +0,01, sans correction pour comparaisons multiples), sans rattraper M2CAN réglé ni le plancher sources seules. L'écart du graphe des plus proches voisins à M2CAN sur l'esthétique (+1,71, IC > 0) n'est pas rapporté comme résultat : la configuration a été choisie comme la meilleure des six sur le même test, et son écart à la méthode n'est pas significatif.

TABLE 5 – Leviers sur l'espace fusionné, exactitude au dernier point (%), moyenne de neuf runs ; entre parenthèses, l'écart apparié à la méthode quand il est significatif.

configuration	HAC	esthétique	sentiment
méthode	88,64	65,07	47,35
maximisation de l'information, poids 0,3	**89,08**	65,14	48,17 (+0,82, 9/9)
maximisation de l'information, poids 1	88,66	65,16	**50,41** (+3,07, 7/9)
SupCon sur z normalisé	88,37	64,31	46,56
graphe des 15 plus proches voisins	87,48	**65,70**	48,39
fin de WBHR et z normalisé	88,71	64,36	47,84
plancher logistique sur z (méthode)	86,64	60,06	48,53

Où est le goulot. Les diagnostics localisent le facteur limitant par famille. Sur HAC, une sonde linéaire dans z donne la même exactitude que la partition et la partition est quasi parfaite : z est structuré en groupes qui coïncident avec les classes. Sur l'esthétique, sonde et partition coïncident à un niveau plus bas : la limite est la séparabilité des classes dans z. Sur le sentiment, deux cas se présentent. Sur TumEmo, la sonde atteint 66,7 alors que la partition donne 47,2 : z sépare les classes mais n'a pas de structure en groupes, et la partition échoue. Sur Yelp, la cible est isolée des sources dans z (MMD^2 de 0,249, quatre à trente fois celle des autres cibles) et la sonde tombe à 50,9 : l'espace z lui-même ne transfère pas. De plus, le plancher logistique sur z de la méthode (48,53) est inférieur au plancher sur les caractéristiques brutes (51,38) : sur le sentiment, l'entraînement dégrade l'information que les caractéristiques contiennent, avec ou sans pseudo-étiquettes. Les deux correctifs qui aident sur le sentiment, la maximisation de l'information et le classifieur de WBHR, sont ceux qui ne dépendent pas de la partition.

4.5 Discussion

Domaine de validité. La méthode suppose que les classes forment des groupes dans l'espace fusionné. C'est le cas de classes catégorielles, comme des actions ; ce n'est pas le cas de classes ordinales. La polarité d'un sentiment (négatif, neutre, positif) est un axe continu dont la classe neutre est le milieu, non un groupe ; la classe esthétique est un seuil sur un score continu. Une partition en K groupes sur un axe coupe à des endroits arbitraires, alors qu'un classifieur entraîné sur les sources y trace une frontière. Le sentiment viole la condition et la méthode y passe sous un plancher sans adaptation. Imposer des groupes de même taille rétablirait des partitions plausibles, mais injecterait la distribution des classes de la cible, que l'on n'est pas censé connaître ; nous avons écarté cette option.

Alignement entre modalités. Le terme CMCFA suppose que les modalités d'un exemple disent la même chose. Sur HAC, audio et vidéo décrivent la même action. Sur Twitter et Yelp, l'image est souvent sans rapport avec la polarité du texte, et forcer l'alignement peut effacer le signal du texte, ce que suggère la dégradation de z sous le plancher brut. Mesurer CMCFA sur les sources seules est l'expérience suivante.

Transductivité. L'inférence partitionne l'ensemble de test ensemble ; la méthode ne prédit pas un exemple isolé, alors que M2CAN prédit chaque point indépendamment. Toute comparaison porte cette réserve.

Caractéristiques gelées. Tous les résultats portent sur des encodeurs gelés, ce qui coûte aux deux méthodes : M2CAN publié avec BERT et ResNet-50 entraînés atteint 84,7 sur Twitter, contre 59,07 ici. Son ablation sans auto-apprentissage (UACR), encodeurs toujours entraînés, donne 55,9 en sentiment et 64,5 en esthétique en moyenne [20, tableau 5], des moyennes proches de celles de M2CAN réglé sur caractéristiques gelées (55,80 et 63,99), mais les valeurs par cible s'écartent jusqu'à 8 points ; que le gain de l'auto-apprentissage exige des encodeurs adaptables reste une hypothèse, non testée directement. Notre reproduction de M2CAN de bout en bout sur AVA (une graine, taux du texte de l'article) donne 77,9 au dernier point, qui est aussi le meilleur, avec une courbe plate à partir de la troisième époque : M2CAN ne dérive pas. La méthode est entraînée 3 époques contre 10 pour M2CAN ; à 10 époques elle perd 3,15 point sur l'esthétique (IC95 $[-4{,}63; -1{,}66]$), par dérive. Un pilote de bout en bout, encodeurs entraînés, sur AVA avec une graine, a donné une partition effondrée (groupes de 722 et 125 points pour deux classes équilibrées), avec ou sans maximisation de l'information ; les critères d'extension écrits avant le run n'étaient pas remplis et le bout en bout a été arrêté. Ce pilote comptait $3 \times 847 = 2\,541$ pas, contre 11 250 dans le cadre gelé, où la courbe d'AVA n'atteint que 59 à 61 % au pas 2 250 et 66 % au pas 3 000 : le bout en bout obtenu (57 à 59) correspond au niveau du cadre gelé au même nombre de pas, et un sous-entraînement de la fusion est l'explication la plus simple. Un budget de pas comparable, ou des taux d'apprentissage de la fusion et des têtes dix fois plus élevés comme ceux de M2CAN, et une montée en régime (encodeurs gelés et pseudo-étiquettes inactives pendant la première époque) restent à évaluer.

Puissance statistique. Trois graines par cible et neuf paires par comparaison donnent des intervalles larges : sur HAC, un écart de ± 4 points à M2CAN n'est pas détectable. Les comparaisons multiples de la Tableau 5 ne sont pas corrigées. Le dernier point d'évaluation évite le biais du meilleur point ; un critère d'arrêt sans étiquette fondé sur le ratio des distances intra et inter-groupes perd deux points en moyenne et a été abandonné.

5 Conclusion

Nous avons proposé une méthode d'adaptation de domaine multi-sources et multimodale qui remplace le classifieur sur l'espace fusionné par un étiquetage géométrique de la cible : agrégation des classes sources par barycentres de Wasserstein, partition spectrale de la cible, transport optimal hiérarchique et appariement hongrois, exécutés pendant l'entraînement comme source de pseudo-étiquettes filtrées par l'accord des modalités. Dans un protocole apparié à caractéristiques gelées, elle atteint le niveau de M2CAN réglé sur la reconnaissance d'actions et l'évaluation esthétique, et lui est inférieure sur l'analyse de sentiment. L'étude d'ablation établit que les pseudo-étiquettes sont le mécanisme décisif sur les actions, que le barycentre est un meilleur représentant sans changer les étiquettes, que le transport hiérarchique devance le transport plat sans significativité, et que le facteur limitant est l'existence d'une structure en groupes dans l'espace fusionné, absente pour des classes ordinales. Les travaux futurs portent sur cette structure : restreindre l'alignement entre modalités aux sources quand les modalités ne sont pas redondantes ; combiner la maximisation de l'information et le classifieur de WBHR, qui agissent sur des mécanismes distincts ; une fusion par attention pondérant les modalités selon l'exemple ; une montée en régime pour l'entraînement de bout en bout ; et une partition de la cible fondée sur des distances de Wasserstein entre structures locales.

Références

[1] Nicolas Courty, Rémi Flamary, Devis Tuia, and Alain Rakotomamonjy. Optimal transport for domain adaptation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(9) :1853–1865, 2017. doi : 10.1109/TPAMI.2016.2615921.

[2] Marco Cuturi. Sinkhorn distances : Lightspeed computation of optimal transport. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 26, 2013.

[3] Marco Cuturi and Arnaud Doucet. Fast computation of Wasserstein barycenters. In *Proceedings of the 31st International Conference on Machine Learning (ICML)*, volume 32 of *Proceedings of Machine Learning Research*, pages 685–693, 2014.

[4] Hao Dong, Ismail Nejjar, Han Sun, Eleni Chatzi, and Olga Fink. SimMMDG : A simple and effective framework for multi-modal domain generalization. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, 2023.

[5] Hao Dong et al. Advances in multimodal adaptation and generalization : From traditional approaches to foundation models. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2026. arXiv :2501.18592.

[6] Mourad El Hamri, Younès Bennani, and Issam Falih. Hierarchical optimal transport for unsupervised domain adaptation. *Machine Learning*, 111(11) :4159–4182, 2022. doi : 10.1007/s10994-022-06231-7.

[7] Mourad El Hamri, Younès Bennani, and Issam Falih. Theoretical guarantees for domain adaptation with hierarchical optimal transport. *Machine Learning*, 114(5), 2025. doi : 10.1007/s10994-025-06749-6.

[8] Mourad El Hamri, Issam Falih, and Yves Rozenholc. Hierarchical representation for multi-source domain adaptation via Wasserstein barycenter. In *IEEE International Conference on Machine Learning and Applications (ICMLA)*, 2025.

[9] Yuan Gong, Yu-An Chung, and James Glass. AST : Audio spectrogram transformer. In *Proceedings of Interspeech*, pages 571–575, 2021.

[10] Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, and Dilip Krishnan. Supervised contrastive learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, 2020.

[11] Jin-Hwa Kim, Kyoung-Woon On, Woosang Lim, Jeonghee Kim, Jung-Woo Ha, and Byoung-Tak Zhang. Hadamard product for low-rank bilinear pooling. In *International Conference on Learning Representations (ICLR)*, 2017.

[12] Harold W. Kuhn. The hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1-2) :83–97, 1955. doi : 10.1002/nav.3800020109.

[13] Songtao Li and Hao Tang. Multimodal alignment and fusion : A survey. *International Journal of Computer Vision*, 134(3), 2025. doi : 10.1007/s11263-025-02667-1.

[14] Jian Liang, Dapeng Hu, and Jiashi Feng. Do we really need to access the source data ? source hypothesis transfer for unsupervised domain adaptation. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, volume 119 of *PMLR*, pages 6028–6039, 2020.

[15] Eduardo Fernandes Montesuma and Fred Maurice Ngolè Mboula. Wasserstein barycenter for multi-source domain adaptation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[16] Gabriel Peyré and Marco Cuturi. Computational optimal transport : With applications to data science. *Foundations and Trends in Machine Learning*, 11(5–6) :355–607, 2019. doi : 10.1561/2200000073.

[17] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 of *PMLR*, pages 8748–8763, 2021.

[18] Ulrike von Luxburg. A tutorial on spectral clustering. *Statistics and Computing*, 17(4) : 395–416, 2007. doi : 10.1007/s11222-007-9033-z.

[19] Limin Wang, Yuanjun Xiong, Zhe Wang, Yu Qiao, Dahua Lin, Xiaoou Tang, and Luc Van Gool. Temporal segment networks : Towards good practices for deep action recognition. In *European Conference on Computer Vision (ECCV)*, 2016.

[20] Sicheng Zhao, Jing Jiang, Wenbo Tang, Jiankun Zhu, Hui Chen, Pengfei Xu, Björn W. Schuller, Jianhua Tao, Hongxun Yao, and Guiguang Ding. Multi-source multi-modal domain adaptation. *Information Fusion*, 117 :102862, 2025.