Étiquetage géométrique de la cible par barycentres de Wasserstein pour l'adaptation de domaine multi-sources et multimodale

Kevin Djoumessi
Faculté des Sciences, Université de Yaoundé I, Yaoundé, Cameroun
kevin.djoumessi@facsciences-uy1.cm

Compléter la liste des auteurs et des affiliations.

29 octobre 2026

Résumé

Nous étudions l'adaptation de domaine multi-sources et multimodale : plusieurs domaines sources étiquetés, un domaine cible sans étiquette, deux modalités par exemple. Les méthodes de référence, telles que M2CAN, alignent les représentations puis entraînent un classifieur sur l'espace fusionné. Nous proposons de retirer ce classifieur et de lire les classes de la cible dans la géométrie de l'espace fusionné : chaque classe source est résumée par le barycentre de Wasserstein de ses nuages dans les différentes sources, la cible est partitionnée par un algorithme spectral, et un transport optimal entre ces structures, suivi d'un appariement hongrois, affecte une classe à chaque groupe. Cet étiquetage, dérivé de HOT-DA et de WBHR, est exécuté périodiquement pendant l'entraînement et fournit des pseudo-étiquettes à une perte contrastive supervisée sur l'espace fusionné. Sur des caractéristiques gelées (CLIP, AST), avec un protocole apparié par cible et par graine et des protocoles écrits avant les mesures, la méthode atteint le niveau de M2CAN réglé sur deux familles de jeux sur trois (reconnaissance d'actions HAC : 88,64 contre 88,36 ; évaluation esthétique : 65,07 contre 63,99 ; écarts non significatifs), et les pseudo-étiquettes apportent +7,19 points sur HAC (IC95 [+2,22; +12,17]). Sur l'analyse de sentiment, la méthode est inférieure à M2CAN (−8,45) et passe sous un plancher sans adaptation. Nos diagnostics montrent que l'appariement des groupes aux classes est optimal dans la quasi-totalité des runs et que le facteur limitant est la partition de la cible, c'est-à-dire l'existence d'une structure en groupes dans l'espace fusionné. Nous rapportons également deux hypothèses sur le rôle du barycentre et du transport hiérarchique, et une variante fidèle à WBHR.

1 Introduction

L'adaptation de domaine non supervisée cherche à prédire les étiquettes d'un domaine cible, pour lequel seules des entrées sont disponibles, à partir d'un ou plusieurs domaines sources étiquetés dont la distribution diffère [1]. Le cadre multi-sources et multimodal (MSMMDA) ajoute deux difficultés : les sources sont plusieurs et ne se recouvrent pas, et chaque exemple est décrit par plusieurs modalités, par exemple un texte et une image, ou une piste audio et une vidéo [5, 20]. La méthode de référence pour ce cadre, M2CAN [20], encode chaque modalité, aligne les représentations par des pertes contrastives entre modalités et entre domaines, les fusionne par un produit bilinéaire de rang faible [11], puis entraîne un classifieur sur l'espace fusionné.

Le transport optimal offre une autre lecture de l'adaptation. HOT-DA [6, 7] représente chaque domaine comme une mesure sur des structures, les classes pour la source et des groupes pour la cible, et résout un problème de transport entre structures avant d'apparier chaque groupe à une classe. WBHR [8] étend cette représentation hiérarchique au cas multi-sources en résumant chaque classe, à travers les sources, par un barycentre de Wasserstein [3, 15]. Ces méthodes

opèrent sur des caractéristiques fixes, après coup.

Nous proposons de placer cet étiquetage géométrique à l'intérieur de l'entraînement d'une fusion multimodale, et de supprimer le classifieur sur l'espace fusionné. Les classes de la cible sont lues par la géométrie : barycentres de Wasserstein des classes sources, partition spectrale de la cible, transport entre structures et appariement. Cet étiquetage est exécuté périodiquement pendant l'apprentissage ; les étiquettes qu'il produit, filtrées par l'accord des têtes unimodales, entrent dans une perte contrastive supervisée sur l'espace fusionné. L'espace que la géométrie lit est ainsi façonné par ce qu'elle y lit.

Nos contributions sont les suivantes.

1. Une méthode d'adaptation multi-sources et multimodale sans classifieur sur l'espace fusionné, où un étiquetage géométrique dérivé de WBHR et de HOT-DA sert d'oracle pendant l'entraînement (Section 3). La méthode accepte un nombre quelconque de sources et de modalités.
2. Une comparaison appariée à M2CAN sur trois familles de jeux (actions, esthétique, sentiment), à caractéristiques gelées identiques, mêmes graines et mêmes découpes, avec des protocoles écrits avant les mesures (Sections 4 et 5). La méthode atteint le niveau de M2CAN sur deux familles et lui est inférieure sur la troisième.
3. Une analyse du mécanisme : l'apport des pseudo-étiquettes, deux hypothèses sur le barycentre et sur le transport hiérarchique, la variante fidèle à WBHR, et des diagnostics qui localisent le facteur limitant dans la partition de la cible plutôt que dans l'appariement (Section 6).

Le code, les configurations et les protocoles sont publics. [1]

2 Travaux liés

Adaptation multi-sources et multimodale. M2CAN [20] définit le cadre MSMMDA et propose six jeux de données textes et images (sentiment : TumEmo, Twitter, Yelp ; esthétique : AVA, PCCD, RPCD). Sa fonction de coût combine une entropie croisée sur des têtes unimodales, un alignement contrastif entre modalités pondéré par la cohérence des têtes (CMCFA), un alignement contrastif supervisé entre domaines (CDCFA) et un classifieur sur la fusion MLB. Nous reprenons les trois premiers termes et remplaçons le quatrième. SimMMDG [4] introduit le jeu HAC (humains, animaux, dessins animés) pour la généralisation multimodale ; nous l'utilisons en adaptation. Les revues de Dong et al. [5] et Li and Tang [13] situent ces travaux.

Transport optimal pour l'adaptation. Courty et al. [1] transportent les sources vers la cible point à point. HOT-DA [6] transporte des structures (classes sources, groupes cibles) et apparie chaque groupe à une classe ; El Hamri et al. [7] en donnent des garanties. WBHR [8] résume chaque classe multi-sources par un barycentre de Wasserstein à support libre [3] avant d'appliquer HOT-DA, puis entraîne un classifieur sur les représentants transportés. Montesuma and Mboula [15] utilisent aussi un barycentre de Wasserstein pour agréger des sources. Les calculs reposent sur la régularisation entropique [2, 16].

Pseudo-étiquettes et maximisation de l'information. SHOT [14] combine une perte de maximisation de l'information sur la cible et des pseudo-étiquettes par centres de classes. Nos pseudo-étiquettes viennent d'une partition de la cible appariée aux classes sources, et nous évaluons la maximisation de l'information comme option (Section 6).

1. https://github.com/Kevindjoum/MM-WBHR

3 Méthode

3.1 Problème et notations

On dispose de N domaines sources étiquetés $\mathcal{S}_1, \dots, \mathcal{S}_N$ et d'un domaine cible $\mathcal{T}$ sans étiquette. Chaque exemple possède M modalités ordonnées $x = (x_0, \dots, x_{M-1})$ et appartient à l'une de K classes. Le train cible sert à l'entraînement sans ses étiquettes ; le test cible sert à l'évaluation. La méthode est transductive : elle partitionne un ensemble de points cibles et ne prédit pas un point isolé.

3.2 Modèle

Encodeurs et têtes unimodales. Pour la modalité m, une dorsale gelée b_m fournit un vecteur de caractéristiques ; un extracteur linéaire $W_m \in \mathbb{R}^{256 \times d_m}$ suivi d'une normalisation donne

$$e_m = \frac{\mathrm{ReLU}(W_m\, b_m(x_m))}{\|\mathrm{ReLU}(W_m\, b_m(x_m))\|} \in \mathbb{R}^{256}. \tag{1}$$

Une tête unimodale g_m, perceptron $256 \to 128 \to 64 \to K$, donne la prédiction $p_m = \mathrm{softmax}(g_m(e_m))$.

Fusion. Les représentations sont fusionnées par un produit bilinéaire de rang faible [11], le même que M2CAN, vers un espace de dimension 256 :

$$z = P\Big(\sigma\big(\bigodot_m U_m e_m\big)\Big) + \textstyle\sum_m h_m(e_m), \tag{2}$$

avec $U_m \colon \mathbb{R}^{256} \to \mathbb{R}^{128}$, $P \colon \mathbb{R}^{128} \to \mathbb{R}^{256}$, $h_m \colon \mathbb{R}^{256} \to \mathbb{R}^{256}$ linéaires, σ la sigmoïde et $\odot$ le produit terme à terme. Aucun classifieur n'est entraîné sur z : les classes de la cible y sont lues par la procédure de la Section 3.4.

3.3 Outils de transport optimal

Le coût entre deux vecteurs est le coût cosinus $c(u, v) = \|u/\|u\| - v/\|v\|\|^2 = 2 - 2\cos(u, v) \in [0, 4]$. Pour une matrice de coût C et deux mesures discrètes a et b, le plan de transport régularisé par l'entropie

$$\Gamma^\star = \underset{\Gamma \mathbf{1} = a,\ \Gamma^\top \mathbf{1} = b}{\arg\min} \ \langle \Gamma,\, C \rangle - \varepsilon H(\Gamma) \tag{3}$$

est calculé par l'algorithme de Sinkhorn en domaine logarithmique [2]. Le coût de transport entre deux nuages X et Y de poids uniformes est $W_\varepsilon(X, Y) = \langle \Gamma^\star, C \rangle$ avec $C_{ij} = c(x_i, y_j)$.

Le barycentre de Wasserstein à support libre de N nuages $X_1, \dots, X_N$ [3] est un nuage $B = (b_1, \dots, b_S)$ de poids $1/S$ minimisant $\sum_k W_\varepsilon(B, X_k)$. Il est calculé par point fixe : B est initialisé par S points tirés dans l'union des nuages ; à chaque itération, le plan Γ_k entre B et X_k est calculé pour chaque k, puis chaque point est remplacé par la moyenne de ses projections barycentriques,

$$b_s \leftarrow \frac{1}{N} \sum_{k=1}^{N} S \sum_j \Gamma_k[s, j]\, x_{k,j}. \tag{4}$$

Nous utilisons $S = 16$, $\varepsilon = 0{,}02$, 60 itérations de Sinkhorn et 8 itérations de point fixe, comme l'algorithme 2 de WBHR [8]. La Section 6 montre que la valeur de S n'a pas d'effet.

Algorithme 1 : ÉTIQUETER : étiquetage géométrique de la cible

Input : représentations et étiquettes des sources $\{(z, y)\}_{k \le N}$; représentations cibles $Z_{\mathcal{T}} \in \mathbb{R}^{n \times 256}$; K

Output : étiquettes $\hat{y} \in \{1, \dots, K\}^n$, groupes, marges

foreach *classe* h **do**
  tirer au plus 400 points de classe h dans chaque source;
  $B_h \leftarrow$ barycentre de Wasserstein de ces N nuages, Équation (4) ; `// représentant de la classe`
$C_{ij} \leftarrow c(z_i, z_j)$ pour $z_i, z_j \in Z_{\mathcal{T}}$; $\sigma \leftarrow$ médiane des $C_{ij} > 0$;
$A \leftarrow \exp(-C/\sigma)$, $A_{ii} \leftarrow 1$;
$G_1, \dots, G_K \leftarrow$ partition spectrale de A en K groupes [18];
foreach *classe* h, *groupe* l **do**
  $W_{hl} \leftarrow W_\varepsilon(B_h, G_l)$; `// coût entre structures`
$\Gamma \leftarrow$ plan de Sinkhorn sur W, marges uniformes $1/K$, Équation (3);
$\pi \leftarrow$ appariement hongrois [12] maximisant $\sum_l \Gamma_{\pi(l),l}$;
$\hat{y}_j \leftarrow \pi(\text{groupe}(j))$ pour tout j;
$\text{marge}_j \leftarrow \min_{l \neq \text{groupe}(j)} c(z_j, \bar{c}_l) \,/\, c(z_j, \bar{c}_{\text{groupe}(j)})$, avec $\bar{c}_l$ le centre du groupe l;
return $\hat{y}$, *groupes, marges*

3.4 Étiquetage géométrique de la cible

La procédure ÉTIQUETER (Algorithme 1) reçoit les représentations z et les étiquettes des sources, et les z de n points cibles. Elle renvoie une classe pour chaque point cible.

Les étapes 4 à 10 sont celles de HOT-DA [6] ; le représentant de classe par barycentre multi-sources est celui de WBHR [8]. Deux différences sont à noter. L'appariement est hongrois, donc bijectif, là où le texte de WBHR prend un arg max par classe qui peut envoyer deux classes sur le même groupe. Et l'étiquette finale est celle du groupe apparié : WBHR transporte au contraire les représentants vers leur groupe et entraîne un classifieur sur les points transportés. Cette variante est évaluée à la Section 6.

3.5 Phase d'entraînement

À chaque pas, on tire quatre exemples dans chaque domaine, sources puis cible, avec une vue faible x et une vue augmentée $\tilde{x}$. La perte est

$$\mathcal{L} = \mathcal{L}_{\text{têtes}} + \mathcal{L}_{\text{CMCFA}} + \mathcal{L}_{\text{CDCFA}} + \mathcal{L}_{\text{SC}}^{\text{fus}}, \tag{5}$$

avec des poids égaux à 1. Les trois premiers termes sont ceux de M2CAN [20].

$\mathcal{L}_{\text{têtes}}$ est l'entropie croisée des têtes unimodales sur les sources, $\frac{1}{MN} \sum_{i \le N} \sum_m \text{CE}(g_m(e_m^{(i)}), y^{(i)})$.

$\mathcal{L}_{\text{CMCFA}}$ aligne les modalités de chaque domaine, cible comprise, sans étiquette. Pour un exemple x d'un lot, avec $a = e_0$ et $b = e_1$, l'InfoNCE sur les quatre combinaisons de vues vaut

$$\ell(x) = -\log \frac{\sum_{(u,v)} \exp \langle u_x,\, v_x \rangle}{\sum_{(u,v)} \sum_{x'} \exp \langle u_x,\, v_{x'} \rangle}, \qquad (u, v) \in \{a, \tilde{a}\} \times \{b, \tilde{b}\}, \tag{6}$$

et la cohérence entre les têtes est $V(x) = \text{KL}(p_1 \,\|\, p_0)$ pour $M = 2$ (divergence de Jensen-Shannon des M têtes au-delà). Les exemples où les modalités se contredisent pèsent moins : $\mathcal{L}_{\text{CMCFA}} = \sum_d [\frac{1}{4} \sum_x \ell(x) e^{-V(x)} + \frac{1}{4} \sum_x V(x)]$. Avec $M \ge 3$, l'InfoNCE est moyenné sur les paires de modalités.

$\mathcal{L}_{\text{CDCFA}}$ est une perte contrastive supervisée [10] par modalité, sur les exemples sources réunis, de température $\tau = 0{,}07$:

$$\text{SupCon}(Z, Y, \tau) = -\frac{1}{|A|} \sum_{a \in A} \frac{1}{|P(a)|} \sum_{p \in P(a)} \log \frac{\exp(z_a \cdot z_p / \tau)}{\sum_{b \neq a} \exp(z_a \cdot z_b / \tau)}, \tag{7}$$

où $P(a)$ réunit les exemples de même étiquette que a et A ceux qui en ont au moins un.

$\mathcal{L}_{\text{SC}}^{\text{fus}}$ est le terme propre à la méthode : une perte SupCon sur l'espace fusionné z, portant sur les exemples sources et sur les exemples cibles du lot qui possèdent une pseudo-étiquette,

$$\mathcal{L}_{\text{SC}}^{\text{fus}} = \text{SupCon}\Big(\{z^{(i)}\}_{i \leq N} \cup \{z_j^{\mathcal{T}}\}_{j \in \mathcal{P}},\ \{y^{(i)}\}_{i \leq N} \cup \{\hat{y}_j\}_{j \in \mathcal{P}},\ \tau\Big). \tag{8}$$

C'est le seul terme où les pseudo-étiquettes agissent : un point cible étiqueté h est attiré vers les exemples sources de la classe h dans l'espace fusionné.

3.6 Pseudo-étiquettes

Tous les 750 pas, soit 15 tours $r = 0, \ldots, 14$ sur 3 époques, le modèle passe en évaluation. Les z des sources et ceux d'au plus 3000 exemples du train cible sont calculés, ainsi que la prédiction moyenne des têtes $\bar{p}_j = \frac{1}{M} \sum_m p_{m,j}$. La procédure ÉTIQUETER fournit $\hat{y}_j$, le groupe et la marge de chaque point cible. Deux filtres s'appliquent.

1. *Accord.* Un point n'est retenu que si la prédiction moyenne des têtes désigne la même classe que la géométrie, $\arg\max_h \bar{p}_{j,h} = \hat{y}_j$. Les têtes, fusion tardive des décisions unimodales, ne décident pas ; elles filtrent la décision géométrique, fusion intermédiaire des représentations.
2. *Quota croissant.* Avec $\rho_r = (0{,}3; 0{,}6; 0{,}9; 1{,}0)[\min(r, 3)]$ et n points étiquetés, on garde dans chaque classe au plus $\lfloor \rho_r n / K \rfloor$ points, ceux de plus grande marge.

La table $\{\text{identifiant} \mapsto \hat{y}_j\}$ des points retenus remplace celle du tour précédent et sert jusqu'au suivant. Les vraies étiquettes du train cible ne servent qu'à journaliser la justesse des pseudo-étiquettes.

3.7 Évaluation

Après chaque tour, ÉTIQUETER est appliquée au test cible et l'exactitude des $\hat{y}$ est journalisée, ainsi que deux diagnostics : l'*oracle*, exactitude obtenue avec le meilleur appariement possible des groupes aux classes, qui mesure la qualité de la seule partition ; et le *plancher logistique*, exactitude d'une régression logistique entraînée sur les z des sources et appliquée au test cible, qui mesure ce que vaut z sans étiquetage géométrique. Le résultat rapporté est celui du *dernier* point d'évaluation. Le meilleur point, choisi avec les étiquettes du test, serait optimiste ; nous ne le rapportons jamais.

Hyperparamètres. Adam, $\beta = (0{,}9; 0{,}999)$, taux 5×10^{-5} pour les extracteurs, la fusion et les têtes, décroissance polynomiale $(1 - t/T)^{0{,}9}$ sur $T = 3 \times 3750$ pas ; lot de 4 exemples par domaine ; e_m et z en dimension 256 ; $\tau = 0{,}07$; barycentre : $S = 16$, $\varepsilon = 0{,}02$, 60×8 itérations, 400 points par classe et par source ; transport entre structures : $\varepsilon = 0{,}02$, 300 itérations ; pseudo-étiquettes : période 750, 3000 points, filtre d'accord, quotas $(0{,}3; 0{,}6; 0{,}9; 1)$.

4 Protocole expérimental

Jeux de données. Trois familles, chacune de trois domaines qui servent de cible à tour de rôle, les deux autres étant les sources (Tableau 1). HAC [4] comprend des vidéos d'actions humaines, animales et de dessins animés, avec audio et vidéo. Les familles sentiment et esthétique sont celles de M2CAN [20], avec texte et image. Les découpes sont celles des auteurs de M2CAN et de SimMMDG.

TABLE 1 – Jeux de données. Le test cible est l'ensemble sur lequel l'exactitude est mesurée.

famille	domaines	modalités (dimension)	K	test cible
HAC	human, animal, cartoon	audio AST (768), vidéo CLIP (512)	7	276 / 176 / 218
esthétique	AVA, PCCD, RPCD	texte CLIP (512), image CLIP (512)	2	847
sentiment	TumEmo, Twitter, Yelp	texte CLIP (512), image CLIP (512)	3	1500

Caractéristiques gelées. Toutes les méthodes reçoivent les mêmes vecteurs, extraits une fois par des encodeurs gelés : CLIP ViT-B/32 [17] pour le texte, l'image et la vidéo (moyenne de huit images par segment temporel [19]), AST [9] pour l'audio. Chaque exemple a une vue faible et quatre vues fortes, avec les augmentations de M2CAN. Pour M2CAN, les vecteurs sont complétés par des zéros jusqu'aux dimensions attendues par son code.

Méthodes comparées. M2CAN est exécuté à partir du code de ses auteurs, adapté aux caractéristiques gelées, avec la configuration publiée de chaque cible et 10 époques. Ses taux d'apprentissage publiés sont prévus pour des encodeurs ajustés de bout en bout ; sur caractéristiques gelées, ils figent presque ses couches entraînables. Nous rapportons donc aussi *M2CAN réglé*, dont le taux d'extracteur est porté à 5×10^{-5}, le même que celui de notre méthode. C'est la référence retenue pour toutes les comparaisons. La méthode est entraînée 3 époques. Nous rapportons également la méthode sans pseudo-étiquettes (ablation), un plancher *sources seules* (régression logistique sur les deux modalités concaténées, entraînée sur les sources) et un plancher d'auto-apprentissage naïf (le même modèle avec cinq tours de pseudo-étiquetage par confiance).

Statistiques. Trois graines (123456, 234567, 345678) par cible, soit 9 runs par configuration et par famille. Les écarts entre deux configurations sont appariés par (cible, graine), 9 paires, avec un intervalle de confiance à 95 % de Student à 8 degrés de liberté. Un écart est déclaré en faveur d'une configuration si l'intervalle exclut zéro et si au moins 7 paires sur 9 sont de son côté ; il est déclaré *non significatif* sinon. Les protocoles (configurations, comparaisons, critère) ont été écrits avant chaque série de mesures. Les runs sont déterministes : la méthode relancée avec un code ultérieur reproduit ses chiffres à l'identique.

5 Résultats

5.1 Comparaison à M2CAN

Les Tableaux 2 et 3 donnent le résultat principal. Sur HAC et sur l'esthétique, la méthode atteint le niveau de M2CAN réglé : +0,27 et +1,08 point, écarts non significatifs. Un étiquetage purement géométrique de l'espace fusionné y fait donc aussi bien qu'un classifieur entraîné sur cet espace. Sur HAC, la méthode devance M2CAN sur human (+5,7) et animal (+1,0) et reste derrière sur cartoon (−5,8). Sur le sentiment, la méthode est inférieure à M2CAN réglé de 8,45 points, sur les neuf paires, et passe sous le plancher sources seules (47,35 contre 51,38) : l'étiquetage géométrique y perd de l'information que z contient.

Le réglage du taux d'extracteur de M2CAN est déterminant : il apporte +5 à +10 points selon la famille. Les comparaisons à M2CAN publié, favorables à la méthode, tiennent surtout à cette asymétrie de réglage et ne sont pas retenues.

5.2 Apport des pseudo-étiquettes

Sur HAC, les pseudo-étiquettes apportent +7,19 points (IC95 [+2,22; +12,17], 8/9) ; sur cartoon, la cible la plus éloignée, elles font passer l'exactitude de 61,93 à 76,15. Les pseudo-étiquettes retenues sont justes à 94 à 97 % en fin d'entraînement sur human et animal, à 79 à 85 % sur

TABLE 2 – Exactitude au dernier point (%), moyenne sur trois graines, caractéristiques gelées. En gras, la meilleure valeur de chaque colonne parmi les méthodes d'adaptation. Les planchers ne sont pas appariés aux autres lignes (sous-échantillons différents).

	human	animal	cartoon	moyenne
HAC				
méthode	**93,36**	**96,40**	76,15	**88,64**
méthode sans pseudo-étiquettes	87,32	95,08	61,93	81,44
M2CAN réglé	87,68	95,45	**81,96**	88,36
M2CAN publié	86,23	86,17	77,06	83,16
sources seules / auto-apprentissage	73,79 / 88,04	86,55 / 92,80	71,10 / 81,35	77,15 / 87,40
	AVA	PCCD	RPCD	moyenne
esthétique				
méthode	72,06	62,06	61,08	65,07
méthode sans pseudo-étiquettes	**73,04**	**63,75**	**61,67**	**66,16**
M2CAN réglé	69,62	62,42	59,94	63,99
M2CAN publié	62,38	61,59	58,24	60,74
sources seules / auto-apprentissage	65,80 / 66,98	59,74 / 59,35	54,55 / 59,46	60,03 / 61,93
	TumEmo	Twitter	Yelp	moyenne
sentiment				
méthode	46,02	56,36	39,67	47,35
méthode sans pseudo-étiquettes	44,80	56,38	44,87	48,68
M2CAN réglé	**58,02**	**59,07**	**50,31**	**55,80**
M2CAN publié	52,18	47,89	37,73	45,93
sources seules / auto-apprentissage	51,64 / 55,13	52,07 / 55,49	50,44 / 51,31	51,38 / 53,98

cartoon. Sur une graine, la divergence MMD^2 entre la cible et les sources dans z est divisée par trois à six (cartoon : 0,120 → 0,020) et l'information mutuelle normalisée de la partition augmente (0,51 → 0,65) : les pseudo-étiquettes rapprochent la cible des classes sources dans l'espace fusionné. Sur l'esthétique et le sentiment, elles n'apportent rien, et coûtent même 1,09 point sur l'esthétique : la MMD^2 n'y bouge pas. Leur bénéfice dépend donc de la justesse de l'étiquetage géométrique qui les produit.

6 Analyse du mécanisme

6.1 L'appariement n'est pas le facteur limitant

Dans 184 runs sur 198, l'exactitude au dernier point égale l'oracle de la partition : l'appariement hongrois des groupes aux classes est optimal. Les exceptions sont concentrées sur le sentiment (écart moyen 0,21 point, maximum 10,5). Tout ce qui sépare la méthode d'une exactitude parfaite tient donc à la partition de la cible, c'est-à-dire à l'existence, dans z, de K groupes qui coïncident avec les classes. Ce constat éclaire les trois analyses qui suivent.

6.2 Hypothèses sur le barycentre et le transport hiérarchique

Hypothèse H1. Résumer une classe par le barycentre de Wasserstein de ses nuages dans les sources représente mieux cette classe que la concaténation de ces nuages.
Hypothèse H2. Le transport hiérarchique (partition, transport entre structures, appariement) étiquette mieux la cible qu'un transport direct des points cibles vers les points des représentants de classe.

La Tableau 4 rapporte les deux hypothèses sur HAC, avec un barycentre dont le support a

TABLE 3 – Écarts appariés par (cible, graine), en points d'exactitude : moyenne, IC95 et nombre de paires en faveur de la première configuration. Verdict selon le critère de la Section 4.

famille	comparaison	écart	IC95	paires / verdict
HAC	méthode − M2CAN réglé	+0,27	[−3,68; +4,22]	5/9, non significatif
HAC	méthode − sans pseudo-étiquettes	+7,19	[+2,22; +12,17]	8/9, **mieux**
HAC	M2CAN réglé − M2CAN publié	+5,21	[+2,41; +8,01]	8/9, mieux
esthétique	méthode − M2CAN réglé	+1,08	[−0,13; +2,28]	7/9, non significatif
esthétique	méthode − sans pseudo-étiquettes	−1,09	[−1,75; −0,43]	0/9, moins bien
esthétique	M2CAN réglé − M2CAN publié	+3,25	[+0,86; +5,64]	9/9, mieux
sentiment	méthode − M2CAN réglé	−8,45	[−12,32; −4,58]	0/9, **moins bien**
sentiment	méthode − sans pseudo-étiquettes	−1,33	[−3,70; +1,03]	5/9, non significatif
sentiment	M2CAN réglé − M2CAN publié	+9,87	[+6,40; +13,33]	9/9, mieux

la taille moyenne de la classe dans les sources, afin que barycentre et concaténation aient des cardinalités comparables.

TABLE 4 – H1 et H2 sur HAC, exactitude au dernier point (%), moyenne sur trois graines.

représentant, transport	human	animal	cartoon	moyenne
barycentre, hiérarchique (méthode)	**93,36**	**96,40**	76,15	**88,64**
concaténation, hiérarchique	**93,36**	**96,40**	76,15	**88,64**
barycentre, plat	91,55	90,53	**76,91**	86,33
concaténation, plat	92,27	90,53	**76,91**	86,57

H1 est partiellement vérifiée. Le barycentre est plus proche, au sens du coût de transport, de la classe cible correspondante que la concaténation, dans 9 cas sur 9 (+0,022 en moyenne). Mais il produit exactement les mêmes étiquettes : le représentant agit sur l'appariement, déjà optimal. Pour la même raison, la taille du support du barycentre (16 points ou taille moyenne de la classe) ne change aucune étiquette sur les trois familles.

H2 est une tendance favorable, non significative. Le transport hiérarchique devance le transport plat de +2,31 point (IC95 [−0,04; +4,65], 7/9), surtout sur animal (+5,9). L'intervalle touche zéro ; le protocole conclut à un résultat non concluant de justesse.

6.3 Variante fidèle à WBHR

WBHR [8] ne s'arrête pas à l'appariement : les points de chaque représentant B_h sont transportés vers leur groupe apparié par projection barycentrique, $\tilde{B}_h = |B_h|\ \Gamma^{\star}_{h,\hat{l}(h)}\ Z_{\hat{l}(h)}$, un classifieur est entraîné sur $\bigcup_h \tilde{B}_h$ étiqueté h et appliqué à tous les points cibles. Nous avons mesuré cette fin (appariement par arg max, régression logistique sur les représentants transportés), seule et avec le support à la taille moyenne de la classe (Tableau 5).

Le classifieur de WBHR n'aide que sur le sentiment (+3,45, 9/9), où il dépasse l'oracle de la partition de 2,3 points : il n'est plus limité par les groupes et corrige une partie des erreurs de la partition. Il ne change rien là où la partition est bonne, et ne suffit pas à rattraper M2CAN réglé ni le plancher sources seules sur le sentiment. La méthode garde donc l'étiquetage par groupe, sans classifieur ; la variante reste une option documentée.

6.4 Leviers sur l'espace fusionné

Six configurations modifiant un seul élément de la méthode ont été comparées, avec un protocole écrit avant les mesures (Tableau 6) : la maximisation de l'information de SHOT [14] sur les

TABLE 5 – Variante fidèle à WBHR, exactitude au dernier point (%), moyenne de neuf runs, et écart apparié à la méthode.

	HAC	esthétique	sentiment
méthode	88,64	65,07	47,35
support à la taille moyenne	88,64	65,07	47,35
fin WBHR (argmax, classifieur)	88,10	65,18	50,88
les deux	**89,34**	**65,16**	**50,80**
les deux − méthode	+0,70 n.s.	+0,09 n.s.	+3,45 [+1,28; +5,63], 9/9
les deux − M2CAN réglé	+0,97 n.s.	+1,17 n.s.	−5,00 [−7,56; −2,44]

têtes du lot cible (poids 0,3 et 1), la perte SupCon de la fusion sur z normalisé, une partition spectrale sur le graphe des 15 plus proches voisins au lieu du graphe complet, et la combinaison du classifieur WBHR et de z normalisé.

TABLE 6 – Leviers sur l'espace fusionné, exactitude au dernier point (%), moyenne de neuf runs. Entre parenthèses, l'écart apparié à la méthode quand il est significatif.

configuration	HAC	esthétique	sentiment
méthode	88,64	65,07	47,35
maximisation de l'information, poids 0,3	**89,08**	65,14	48,17 (+0,82, 9/9)
maximisation de l'information, poids 1	88,66	65,16	**50,41** (+3,07, 7/9)
SupCon sur z normalisé	88,37	64,31	46,56
graphe des 15 plus proches voisins	87,48	**65,70**	48,39
classifieur WBHR et z normalisé	88,71	64,36	47,84
plancher logistique sur z (méthode)	86,64	60,06	48,53

Aucune configuration ne change HAC ni l'esthétique au-delà du bruit. Sur le sentiment, seule la maximisation de l'information aide (+3,07 avec le poids 1, borne basse de l'IC à +0,01, sans correction pour comparaisons multiples) ; elle ne rattrape ni M2CAN réglé (−5,39) ni le plancher sources seules. L'écart du graphe des plus proches voisins à M2CAN sur l'esthétique (+1,71, IC > 0) n'est pas rapporté comme résultat : la configuration a été choisie comme la meilleure des six sur le même test, et son écart à la méthode n'est pas significatif.

6.5 Où est le goulot

Les diagnostics localisent le facteur limitant par famille. Sur HAC, une sonde linéaire dans z donne la même exactitude que la partition et la partition est quasi parfaite : z est structuré en groupes qui coïncident avec les classes, et la géométrie les lit. Sur l'esthétique, sonde et partition coïncident aussi, à un niveau plus bas : la limite est la séparabilité des classes dans z. Sur le sentiment, deux cas se présentent. Sur TumEmo, la sonde atteint 66,7 alors que la partition donne 47,2 : z sépare les classes mais n'a pas de structure en groupes, et la partition échoue. Sur Yelp, la cible est isolée des sources dans z (MMD^2 de 0,249, quatre à trente fois celle des autres cibles) et la sonde tombe à 50,9 : c'est l'espace z lui-même qui ne transfère pas. Les deux correctifs qui aident sur le sentiment, la maximisation de l'information et le classifieur de WBHR, sont précisément ceux qui ne dépendent pas de la partition.

7 Discussion et limites

Ce que la méthode apporte. Un étiquetage de la cible lu dans la géométrie de l'espace fusionné, sans classifieur, atteint le niveau de M2CAN réglé sur deux familles sur trois, et la

boucle qui renvoie cet étiquetage dans l'entraînement est le mécanisme décisif sur HAC. La méthode est native pour N sources, par le barycentre, et pour $M \geq 3$ modalités, par la fusion M-aire et l'InfoNCE sur les paires de modalités, ce que M2CAN ne prévoit pas.

Condition d'application. La méthode suppose que l'espace fusionné soit structuré en groupes qui coïncident avec les classes. Le sentiment viole cette condition et la méthode y passe sous un plancher sans adaptation, alors qu'un classifieur entraîné sur les sources garde un pouvoir de transfert. Imposer des groupes de même taille rétablirait des partitions plausibles, mais injecterait la distribution des classes de la cible, que l'on n'est pas censé connaître ; nous avons écarté cette option.

Transductivité. L'inférence partitionne l'ensemble de test ensemble ; la méthode ne prédit pas un exemple isolé. Les méthodes comparées prédisent chaque point indépendamment. Toute comparaison doit porter cette réserve.

Caractéristiques gelées et bout en bout. Tous les résultats portent sur des encodeurs gelés. Un pilote de bout en bout, encodeurs entraînés, sur AVA avec une graine, a donné une partition effondrée (groupes de 722 et 125 points pour deux classes équilibrées), avec ou sans maximisation de l'information ; les critères d'extension écrits avant le run n'étaient pas remplis et le bout en bout a été arrêté. L'effondrement vient de z, non d'un déséquilibre des têtes.

Puissance statistique. Trois graines par cible et neuf paires par comparaison donnent des intervalles larges : sur HAC, un écart de ± 4 points à M2CAN n'est pas détectable. Les comparaisons multiples de la Tableau 6 ne sont pas corrigées. Le dernier point d'évaluation évite le biais du meilleur point ; un critère d'arrêt sans étiquette fondé sur le ratio des distances intra et inter-groupes a été essayé et perd deux points en moyenne.

8 Conclusion

Nous avons proposé une méthode d'adaptation de domaine multi-sources et multimodale qui remplace le classifieur sur l'espace fusionné par un étiquetage géométrique de la cible, barycentres de Wasserstein des classes sources, partition spectrale, transport entre structures et appariement, exécuté pendant l'entraînement comme source de pseudo-étiquettes. Dans un protocole apparié à caractéristiques gelées, elle atteint le niveau de M2CAN réglé sur la reconnaissance d'actions et l'évaluation esthétique, et lui est inférieure sur l'analyse de sentiment. L'analyse montre que l'appariement est optimal dans la quasi-totalité des runs, que le représentant de classe et la taille de son support n'ont pas d'effet sur les étiquettes, et que le facteur limitant est l'existence d'une structure en groupes dans l'espace fusionné. Les travaux futurs portent sur cette structure : combiner la maximisation de l'information et le classifieur de WBHR, qui agissent sur des mécanismes distincts et aident tous deux sur le sentiment ; une fusion par attention, pondérant les modalités selon l'exemple ; et une partition de la cible fondée sur des distances de Wasserstein entre structures locales, telle que l'annonce WBHR.

Références

[1] Nicolas Courty, Rémi Flamary, Devis Tuia, and Alain Rakotomamonjy. Optimal transport for domain adaptation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(9) :1853–1865, 2017. doi : 10.1109/TPAMI.2016.2615921.

[2] Marco Cuturi. Sinkhorn distances : Lightspeed computation of optimal transport. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 26, 2013.

[3] Marco Cuturi and Arnaud Doucet. Fast computation of Wasserstein barycenters. In *Proceedings of the 31st International Conference on Machine Learning (ICML)*, volume 32 of *Proceedings of Machine Learning Research*, pages 685–693, 2014.

[4] Hao Dong, Ismail Nejjar, Han Sun, Eleni Chatzi, and Olga Fink. SimMMDG : A simple and effective framework for multi-modal domain generalization. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, 2023.

[5] Hao Dong et al. Advances in multimodal adaptation and generalization : From traditional approaches to foundation models. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2026. arXiv :2501.18592.

[6] Mourad El Hamri, Younès Bennani, and Issam Falih. Hierarchical optimal transport for unsupervised domain adaptation. *Machine Learning*, 111(11) :4159–4182, 2022. doi : 10.1007/s10994-022-06231-7.

[7] Mourad El Hamri, Younès Bennani, and Issam Falih. Theoretical guarantees for domain adaptation with hierarchical optimal transport. *Machine Learning*, 114(5), 2025. doi : 10.1007/s10994-025-06749-6.

[8] Mourad El Hamri, Issam Falih, and Yves Rozenholc. Hierarchical representation for multi-source domain adaptation via Wasserstein barycenter. In *IEEE International Conference on Machine Learning and Applications (ICMLA)*, 2025.

[9] Yuan Gong, Yu-An Chung, and James Glass. AST : Audio spectrogram transformer. In *Proceedings of Interspeech*, pages 571–575, 2021.

[10] Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, and Dilip Krishnan. Supervised contrastive learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, 2020.

[11] Jin-Hwa Kim, Kyoung-Woon On, Woosang Lim, Jeonghee Kim, Jung-Woo Ha, and Byoung-Tak Zhang. Hadamard product for low-rank bilinear pooling. In *International Conference on Learning Representations (ICLR)*, 2017.

[12] Harold W. Kuhn. The hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1-2) :83–97, 1955. doi : 10.1002/nav.3800020109.

[13] Songtao Li and Hao Tang. Multimodal alignment and fusion : A survey. *International Journal of Computer Vision*, 134(3), 2025. doi : 10.1007/s11263-025-02667-1.

[14] Jian Liang, Dapeng Hu, and Jiashi Feng. Do we really need to access the source data ? source hypothesis transfer for unsupervised domain adaptation. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, volume 119 of *PMLR*, pages 6028–6039, 2020.

[15] Eduardo Fernandes Montesuma and Fred Maurice Ngolè Mboula. Wasserstein barycenter for multi-source domain adaptation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[16] Gabriel Peyré and Marco Cuturi. Computational optimal transport : With applications to data science. *Foundations and Trends in Machine Learning*, 11(5–6) :355–607, 2019. doi : 10.1561/2200000073.

[17] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger,

and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 of *PMLR*, pages 8748–8763, 2021.

[18] Ulrike von Luxburg. A tutorial on spectral clustering. *Statistics and Computing*, 17(4) : 395–416, 2007. doi : 10.1007/s11222-007-9033-z.

[19] Limin Wang, Yuanjun Xiong, Zhe Wang, Yu Qiao, Dahua Lin, Xiaoou Tang, and Luc Van Gool. Temporal segment networks : Towards good practices for deep action recognition. In *European Conference on Computer Vision (ECCV)*, 2016.

[20] Sicheng Zhao, Jing Jiang, Wenbo Tang, Jiankun Zhu, Hui Chen, Pengfei Xu, Björn W. Schuller, Jianhua Tao, Hongxun Yao, and Guiguang Ding. Multi-source multi-modal domain adaptation. *Information Fusion*, 117 :102862, 2025.